




Minería de Datos

Alex Di Genova

07/04/2026

Programa

- KDD
- Introducción a las técnicas principales en MD

Visión global




Octubre 2020,
Sebastian
Steudtner
(German)
26 metros

- Astronomía
- Genómica
- Redes Sociales
- Youtube
- Infraestructura (computadores, redes)
- algoritmos y modelos

Knowledge Discovery in Databases - KDD

Datos → información → conocimiento

- **Selección de datos**
Se eligen los datos relevantes desde una o varias fuentes.
Ejemplo: registros de ventas, datos clínicos, sensores, encuestas.
- **Limpieza y preprocesamiento**
Se corrigen errores, se eliminan duplicados, se manejan valores faltantes y ruido.
Esta etapa es clave, porque datos malos producen resultados malos.
- **Transformación de datos**
Los datos se preparan para el análisis.
Esto puede incluir normalización, reducción de dimensiones, agregación o creación de nuevas variables.
- **Minería de datos (Data Mining)**
Aquí se aplican métodos computacionales y estadísticos para identificar patrones.
 - clasificación
 - clustering
 - reglas de asociación
 - regresión
 - detección de anomalías
- **Evaluación e interpretación**
Se revisa si los patrones encontrados son realmente útiles, válidos e interesantes.
No todo patrón descubierto tiene valor práctico.
- **Presentación del conocimiento**
Los resultados se comunican de forma comprensible, por ejemplo, mediante gráficos, reglas, reportes o dashboards.



KDD es el proceso de identificar patrones válidos, nuevos, útiles y comprensibles en conjuntos de datos.

KDD

Ejemplos

• Una tienda tiene miles de compras registradas. • Con KDD puede descubrir que: • Clientes que compran pañales también compran toallitas • Ciertos productos se venden más en fines de semana • Algunos clientes tienen alto riesgo de dejar de comprar • Ese conocimiento luego sirve para marketing, predicción o toma de decisiones	• Bancos y finanzas • Con transacciones financieras, el KDD ayuda a detectar: • Fraude • perfiles de riesgo crediticio • patrones de gasto y comportamiento financiero • Educación • Con datos de estudiantes, asistencia y calificaciones, se puede descubrir: • factores asociados al bajo rendimiento • riesgo de deserción • perfiles de aprendizaje	• Redes sociales y plataformas web • Con clics, publicaciones o interacciones, se pueden encontrar: • patrones de comportamiento de usuarios • contenido más relevante o viral • segmentos de usuarios con intereses similares • Transporte y ciudades inteligentes • Con datos de tráfico, GPS y transporte público, se pueden descubrir: • horas y zonas de congestión • rutas más eficientes • patrones de movilidad urbana
---	--	--

¿Cuántos datos se necesitan para aplicar KDD?



- La cantidad depende de la dificultad del problema, del ruido y del número de variables.
- 1. Clasificación
 - La **clasificación** busca predecir una categoría o clase, por ejemplo:
 - spam / no spam
 - enfermo / sano
 - cliente que compra / no compra
 - **Decenas de ejemplos por clase:** solo para ejercicios simples o demostraciones.
 - **Cientos por clase:** permite entrenar modelos con algo de estabilidad.
 - **Miles o más por clase:** recomendable para aplicaciones reales, sobre todo si hay muchas variables.
 - Importante:
 - Tener ejemplos de todas las clases.
 - Evitar clases muy desbalanceadas.
 - Tener suficientes casos para entrenamiento y prueba.
 - **Regla práctica**
 - Si una clase tiene muy pocos ejemplos, el modelo aprenderá mal esa categoría.

Técnicas principales en MD

Algoritmos de Minería de Datos

Clases


- Modelos estadísticos
- Supervisados
 - clasificación
 - Regresión
- No-supervisados
 - Reducción de dimensionalidad
 - Clustering
 - Analisis de asociación



Técnicas MD

Clasificación

- Aprende a separar entre clases a partir de ejemplos etiquetados.
- ¿Qué responde?
- Es spam o no spam?
- ¿Paciente con bajo o alto riesgo?
- ¿Cliente abandonara o permanecerá?



El algoritmo kNN calcula la distancia entre los casos sin etiqueta y todos los datos con etiqueta


Dime con quién andas y te diré quién eres.

Técnicas MD


Regresión

- Modela una relación continua entre variables predictoras y una respuesta numérica.
- ¿Qué responde?
 - ¿Cuál será el precio de una vivienda?
 - ¿Cuántas ventas se esperan la próxima semana?
 - ¿Qué tiempo de recuperación tendrá un paciente?

Imagina que quieres predecir el pH de lotes de sidra a partir de la cantidad de manzana contenida en cada lote (en kilogramos).



$$y = \beta_0 + \beta_1 x_1 + \epsilon$$







$$\begin{aligned}\beta_1 &= \frac{\Delta y}{\Delta x} \\ &= \frac{-0.105}{1} \\ &= -0.105\end{aligned}$$

Slope: como cambia Y cuando X incremente 1 unidad

Técnicas MD

Reduccion de dimensionalidad


- Resume muchas variables en pocas componentes conservando estructura o variabilidad.
- ¿Qué responde?
- ¿Cómo visualizar datos de alta dimensión?
- ¿Qué variables sintetizan/explican mejor la información?
- ¿Cómo reducir ruido y redundancia?



Técnicas MD

Clustering

- Un clúster es un conjunto de casos que son más similares entre sí que a los casos de otros clústeres.
- ¿Qué responde?
- ¿Existen perfiles/grupos en los datos?
- ¿Qué clientes o pacientes son similares entre sí?
- ¿Cómo segmentar poblaciones heterogéneas?



5 iteraciones de k-means

Se generan aleatoriamente tres centros iniciales en el espacio de características. Los casos se asignan al clúster de su centro más cercano. En cada iteración, cada centro se desplaza hacia la media de los casos de su clúster

Técnicas MD

Análisis de asociación

- Descubre co-ocurrencias frecuentes y reglas del tipo $A \rightarrow B$ en datos transaccionales.
- ¿Qué responde?
 - ¿Qué elementos aparecen juntos con frecuencia?
 - ¿Qué combinaciones sirven para recomendar?
 - ¿Qué patrones de co-ocurrencia se repiten?

Base de transacciones

T1: {Pan, Leche}

T2: {Pan, Mantequilla}

T3: {Leche, Mantequilla}

T4: {Pan, Leche, Mantequilla}

T5: {Pan, Leche}

Objetivo:

Encontrar conjuntos frecuentes de

Soporte mínimo = 2 transacciones.

Idea central:

- 1) generar candidatos
- 2) contar su soporte
- 3) eliminar los no frecuentes
- 4) repetir con conjuntos más grandes

Resultado final


Conjuntos frecuentes encontrados:

L1 = {Pan}, {Leche}, {Mantequilla}


L2 = {Pan, Leche}, {Pan, Mantequilla}, {Leche, Mantequilla}

L3 = $\emptyset$

Apriori funciona porque si un conjunto NO es frecuente, ninguno de sus superconjuntos puede serlo.



Métodos estadísticos



1. Comparar una media con un valor de referencia

Pregunta

- ¿La media de una variable es distinta de un valor conocido?
- Ejemplo: ¿el promedio de presión arterial es distinto de 120?

Test

- **t de una muestra**
- Si no se cumple normalidad y la muestra es pequeña: **Wilcoxon de una muestra**

2. Comparar medias entre dos grupos independientes

Pregunta

- ¿El promedio de una variable difiere entre dos grupos?
- Ejemplo: ¿la nota promedio difiere entre hombres y mujeres?

Test

- **t de Student para muestras independientes**
- Si las varianzas no son iguales: **t de Welch**
- Si no hay normalidad: **Mann–Whitney U**

13. Modelar efecto de una variable sobre otra numérica

Pregunta

- ¿X tiene efecto sobre Y continua?
- Ejemplo: ¿la edad predice presión arterial?

Test / enfoque

- **Regresión lineal**

4. Comparar medias entre tres o más grupos independientes

Pregunta

- ¿Existen diferencias de medias entre varios grupos?
- Ejemplo: ¿el rendimiento difiere entre 3 métodos de enseñanza?

Test

- **ANOVA de una vía**
- Si no hay normalidad: **Kruskal–Wallis**

**¿Consultas o
comentarios?**